

PRÁCTICA FINAL

Parte 1/3: Diseño e implementación

Una empresa desarrolla una plataforma de streaming y necesita diseñar la base de datos que gestione la información de usuarios, contenidos y visualizaciones.

Cada usuario se identifica por su correo electrónico, y además se guarda su nombre y apellidos, edad, antigüedad en la plataforma y contraseña hasheada (MD5). Los usuarios también pueden “seguir” a otros usuarios, lo que les permite ver lo que ha visto ese otro usuario, etc.

Los usuarios pueden tener como mucho un plan de membresía activo en la plataforma. Pueden no tener ningún plan de membresía, y aun así acceder a ciertas características de la plataforma (gestión de cuenta, etc). Queremos guardar la fecha de caducidad de la validez del plan

Los planes de membresía tienen las siguientes características

- Identificador numérico único para cada plan
- Precio mensual
- Nombre comercial del plan
- Fecha de creación del plan
- Listado de países donde el plan está disponible para adquirir. Puede no estar disponible para ningún país, o disponible para todos

En la plataforma hay contenido para su consumo por los usuarios. Todos los tipos de contenido tienen las siguientes características.

- Identificador único
- Fecha de publicación
- Planes en los que el contenido está disponible. Un contenido puede estar disponible en varios planes o ninguno. También queremos guardar la fecha en la que el contenido se añadió al plan
- Clasificación por edad
- Duración
- Género
- Lista de idiomas en la que el contenido está disponible

Además de estas características comunes, existen tipos de contenido, cada uno con sus características particulares

Capítulos de series

Los capítulos de las series tienen las siguientes características adicionales

- Nombre del capítulo
- Temporada
- Número del capítulo
- Reparto (Actores que participan en el capítulo. Queremos guardar su nombre, fotografía y fecha de nacimiento)

Audiolibros

- Autor del audiolibro
- Narrador del audiolibro

Películas

- Director
- Reparto (Actores que participan en el capítulo. Queremos guardar su nombre, fotografía y fecha de nacimiento)

Aparte de guardar los capítulos de las series, también necesitamos guardar la siguiente información sobre las series en sí.

- Número de temporadas
- Nombre de la serie, no hay dos series con el mismo nombre.

Los usuarios consumen el contenido de la plataforma. Un usuario puede hacer lo siguiente con el contenido disponible.

- Marcarlo como Favorito.
- Otorgarle una puntuación (1 a 5 estrellas)
- Si en algún momento ha visualizado el contenido, se guarda el momento en el que paró la visualización.
- Si lo visualizó completamente, se marca el contenido como visto

Ejercicio 1: Diseño preliminar

Haz el modelo entidad relación del ejercicio, indicando claramente la cardinalidad de las relaciones.

En función del modelo entidad relación, realiza el modelo relacional, indicando claramente claves primarias y claves foráneas y comprobando que las tablas resultantes cumplen la tercera forma normal.

- Alcance de la entrega del ejercicio:
 - Modelo Entidad-Relación
 - Modelo Relacional
 - Para decisiones no triviales, explica tu proceso de razonamiento y por qué has tomado esa decisión con respecto a otras posibles.

Ejercicio 2: Diseño adaptado a las necesidades de negocio

Nota 1: Si alguno de los requisitos no fuese implementable tal cual aparece en el enunciado, explica por qué y qué solución alternativa propones para obtener la misma funcionalidad e impleméntala.

Nota 2: Puedes usar las siguientes funciones

- `USER ()` : Devuelve el usuario autenticado (el que se ha conectado a MySQL)
- `CURRENT_USER ()` : Devuelve el usuario con los privilegios reales para la ejecución. En el caso de un trigger, puede no ser el mismo que devuelve `USER ()`
- `CURRENT_ROLE ()` : Devuelve el rol del usuario.
- Para activar un rol en un usuario que tiene permisos para usar ese perfil puedes utilizar: `SET ROLE 'mi_rol'`. Hasta que el usuario no active el rol, no se podrán utilizar los permisos asociados a ese rol

El cliente nos indica los siguientes requisitos adicionales necesarios para el cumplimiento de una certificación necesaria para su negocio:

- La empresa requiere que la relación de usuarios y contraseñas hasheadas esté separada del resto de la tabla usada para los usuarios. De esta manera, se limita el número de entidades con acceso a esa tabla, y por tanto se limitan ciertos tipos de ataque, como por ejemplo aquellos mediante una tabla Rainbow (relación precomputada entre strings y hashes) en el caso de que el contenido de la tabla sea filtrado.
- La empresa va a contratar un servicio de backup para su base de datos, que sólo deberá de tener permisos de lectura. El usuario se deberá de llamar `backup_generic_readonly`. La empresa quiere que este usuario no tenga permiso a la tabla que alberga la relación de usuarios y contraseñas hasheadas, para evitar posibles riesgos de filtraciones en la empresa contratada. En el caso de que se pierda la relación de usuarios y contraseñas, los usuarios deberán resetear sus contraseñas, que en cualquier caso es preferible al riesgo de que se filtre la relación entre usuarios y contraseñas hasheadas. Tampoco quiere que esta empresa tenga acceso al contenido a la relación de los usuarios con el contenido (Puntuaciones,

favoritos, visto...) por considerarse información de valor estratégico al que no debería tener acceso esta empresa

- La empresa quiere contratar otro servicio de backup en otra empresa, sólo para hacer backup únicamente de la relación de los usuarios con el contenido (Puntuaciones, favoritos, visto...). La razón de querer sólo hacer backup de estos datos en concreto es que el servicio de backup de esta empresa es mucho más caro que la anterior, debido a que nos garantiza que guardará la información encriptada “at rest”, por eso sólo queremos usarla para esos datos. El usuario que crearemos para esta empresa se deberá llamar `backup_sensible_readonly`
- Crear un Rol en MySQL que sea `backoffice`. El objeto de este rol es que se le otorgue a los distintos usuarios que utilizan nuestra base de datos desde una aplicación de `backoffice` (servicio de atención al cliente, gestores de contenido, etc). Esto es, si hay un cliente web, crearemos un usuario con el rol `backoffice` para esa aplicación web, si hay un cliente pesado (de escritorio), se le creará otro usuario con este mismo rol, etc. Este usuario que hemos creado para el cliente web no es el mismo usuario que la persona que está utilizando el aplicativo, sino que es para el aplicativo en sí.
- Crea un usuario que se llame `web_client` con el rol de `backoffice`.
- La empresa no quiere que los usuarios con el rol `backoffice` puedan borrar físicamente en la tabla `contenido` de la base de datos, pero quiere implementar la funcionalidad de borrado de cara al usuario. Para esto, nos propone crear dos campos adicionales en nuestra tabla para el contenido, uno que sea `borrado_backoffice` que sea de tipo booleano en el que se represente si el mensaje se ha borrado desde el aplicativo y otro que sea `fecha_borrado_backoffice` en el que se indique la fecha de “borrado” desde el aplicativo. Nos propone también crear una vista que el aplicativo utilice a modo de tabla de contenido, llamada `contenido_backoffice`. En esta vista, los usuarios con rol `backoffice` sólo verán las filas cuyo valor para el campo `borrado_backoffice` = 0. A la hora de eliminar datos sobre esta vista para los usuarios con este rol, se lanzará un trigger que pondrá el campo `borrado_backoffice` = 1 y `fecha_borrado_backoffice` con la fecha de cuándo se hizo el “borrado”, sin borrar el contenido realmente. Los campos `borrado_aplicativo` y `fecha_borrado_aplicativo` no serán visibles desde la vista `contenido_backoffice`.
- Crear una tabla llamada `auditoria_administrador_plan` que para usuarios con rol de `administrador` registre cualquier cambio realizado sobre la tabla de plan. Esta tabla debe tener los mismos campos que la tabla `plan`, pero sólo se guardarán los campos que han sido modificados, además debe almacenar el tipo de operación que se ha usado para modificar (INSERT, UPDATE o DELETE), la hora del cambio y el usuario que hizo el cambio. Esta tabla no será accesible para ningún usuario excepto para el super administrador (tú).
- Crear un Rol en MySQL que sea `administrador`. Los administradores tienen todos los permisos, excepto que no tienen que tener acceso de ningún tipo a la tabla `auditoria_administrador_plan`.
- Crea un usuario que se llame `administrador_andres_perez_indra` con el rol de `administrador`

- Todos los usuarios creados deberán tener exclusivamente los permisos necesarios para hacer su función correctamente.
- Alcance de la entrega del ejercicio:
 - Nuevo modelo relacional
 - Relación de roles, usuarios creados y sus contraseñas y permisos asignados tanto a roles como a usuarios
 - Consultas que has usado para crear las vistas que se solicitan, y los permisos sobre estas vistas.
 - Cualquier otro desarrollo que hayas hecho sobre la base de datos (triggers, etc) y los permisos sobre estos

Ejercicio 3: Implementación del diseño

Después de aplicar los cambios del ejercicio 2, aplica los cambios al modelo físico e impleméntalo en una base de datos MySQL.

Esta implementación la puedes hacer en local o en AWS.

- Alcance de la entrega del ejercicio:
 - IP o dominio, puerto, usuario superadministrador y contraseña de la instancia donde hayas implementado el esquema de la base de datos en el caso de que la implementación haya sido en AWS. Este servidor debe de ser accesible desde internet.
 - Si la implementación ha sido en local, entrega una exportación autocontenida en un único fichero llamada `streaming.sql`

Parte 2/3: Consultas

Ejercicio 4: Consultas

- Alcance de la entrega del ejercicio:
 - Por cada consulta, indica la consulta utilizada, y si así lo consideras por la complejidad de la consulta, explica por qué has decidido hacerla de esa manera.
1. Obtener los 10 contenidos más vistos, medido como el número de usuarios que los han marcado como vistos.
 2. Obtener los 10 contenidos con mayor puntuación media, considerando solo aquellos que tengan al menos 50 puntuaciones.
 3. Encontrar los contenidos con mayor desviación en las puntuaciones (contenidos más polarizantes), considerando solo aquellos con al menos 50 votos. [Nota: recomendable usar la función STDDEV_POP]
 4. Obtener todos los usuarios que tienen un plan activo actualmente.
 5. Encontrar los usuarios que han marcado más de 100 contenidos como favoritos.
 6. Calcular la puntuación media de los contenidos por género, considerando solo puntuaciones existentes.
 7. Obtener los 20 usuarios que han visto más contenidos en la plataforma.
 8. Recomendar contenidos a un usuario basándose en los contenidos favoritos de los usuarios a los que sigue, excluyendo los contenidos que ese usuario ya haya visto. (Recomendación básica: los primeros 20 contenidos más veces marcados como favoritos por los usuarios que sigue el usuario dado, que no haya visto)
 9. Encontrar los usuarios con más contenidos favoritos en común con un usuario dado.
 10. Encontrar los usuarios que han visto todos los contenidos disponibles en un plan determinado.
 11. Obtener los contenidos que nunca han sido vistos por ningún usuario.
 12. Obtener los contenidos que han sido vistos por todos los usuarios de la plataforma.
 13. Encontrar los usuarios que nunca han puntuado ningún contenido.
 14. Encontrar los contenidos más abandonados, es decir, aquellos que los usuarios han empezado a ver pero no han terminado.
 15. Calcular el ratio de finalización de cada contenido, definido como el número de visualizaciones completas dividido entre el número de visualizaciones iniciadas. [Nota: Puedes usar NULLIF(0,0) para evitar divisiones entre 0]
 16. Para cada usuario, encontrar el género de contenido que más ha visto.
 17. Encontrar los usuarios que solo han visto contenidos de un único género.
 18. Obtener los contenidos cuya puntuación media es superior a la media global de puntuaciones de la plataforma.
 19. Encontrar los actores cuyas películas han sido vistas por el mayor número de usuarios distintos.
 20. Encontrar las series que han sido vistas por el mayor número de usuarios, considerando que un usuario ha visto la serie si ha visto al menos uno de sus capítulos.
 21. Encontrar los pares de usuarios (seguidor–seguido) que comparten al menos 20 contenidos favoritos en común.

22. Recomendar contenidos a un usuario basándose en su género más visto, excluyendo los contenidos que ya haya visto.
23. Mostrar las series con mayor número de actores distintos.
24. Mostrar el actor que ha trabajado con más actores distintos.
25. Mostrar los actores que han participado en más contenidos que cualquier otro actor de su misma edad. **[OPCIONAL]**

Parte 3/3: Benchmarking

Población de tablas y evaluación del rendimiento

La empresa desea realizar una demostración del rendimiento del diseño de la base de datos en función de la **volumetría de uso esperada durante los primeros meses de funcionamiento de la plataforma**.

Para ello se deben generar datos sintéticos que simulen el comportamiento esperado de los usuarios y del catálogo de contenidos.

El objetivo es evaluar el rendimiento de las consultas analíticas definidas previamente cuando el volumen de datos aumenta.

Ejercicio 5: Table population

Se deben generar datos que simulen la actividad de la plataforma.

Se crearán dos escenarios de volumen de datos:

- Escenario A: datos equivalentes a 6 meses de actividad
- Escenario B: datos equivalentes a 1 año de actividad

Estimaciones de uso

Usuarios

Número estimado de usuarios:

- 25.000 usuarios a los 6 meses
- 40.000 usuarios al año

Cada usuario:

- tiene edad entre 18 y 70 años
- puede tener 0 o 1 plan de membresía activo
- aproximadamente 78 % de los usuarios tienen plan activo

Relaciones entre usuarios

Los usuarios pueden seguir a otros usuarios.

- Cada usuario sigue entre 0 y 50 usuarios
- La relación de seguimiento no es necesariamente recíproca.

Contenidos de la plataforma

Volumen estimado de contenidos:

Tipo de contenido	6 meses	1 año
Películas	3500	5500
Audiolibros	1200	2000
Series	300	500

Cada serie:

- tiene entre 1 y 5 temporadas
- cada temporada tiene entre 6 y 12 capítulos

Cada contenido tiene:

- género
- duración
- clasificación por edad
- fecha de publicación

Se recomienda utilizar entre 10 y 15 géneros.

Actores

Los actores participan en:

- películas
- capítulos de series

Número estimado:

- 4000 actores a los 6 meses
- 6000 actores al año

Cada contenido tiene entre 2 y 10 actores.

Interacciones de los usuarios

Cada usuario interactúa con entre 100 y 400 contenidos.

Tipos de interacción:

- contenido visto completamente
- contenido abandonado
- contenido marcado como favorito
- contenido puntuado

Distribución aproximada:

- 60 % vistos completamente
- 20 % abandonados
- 30 % favoritos
- 40 % puntuados

Las puntuaciones están entre 1 y 5.

Generación de datos

Se deberá implementar un script usando las tecnologías que libremente se escojan que permita poblar la base de datos automáticamente.

El script debe permitir generar datos para:

- 6 meses
- 1 año

El código debe estar documentado explicando las decisiones tomadas.

Entregables del ejercicio

- Código utilizado para poblar la base de datos
- Volcado de la base de datos a 6 meses y a 1 año (comprimido)
- Explicación de las decisiones tomadas
- Tamaño de la base de datos generado en megabytes, tanto a 6 meses como a un año.

Ejercicio 6: Benchmarking

Con los datos generados se deberán ejecutar las consultas definidas previamente.

Se deberán medir los tiempos de ejecución en los dos escenarios:

- **6 meses**
- **1 año**

Resultados

Elaborar una tabla que incluya:

- número de consulta
 - nombre de la consulta
 - tiempo de ejecución con **6 meses**
 - tiempo de ejecución con **1 año**
 - factor de empeoramiento
 - incremento porcentual
-
- ¿Cuál es la relación entre rendimiento (tiempo de ejecución de las consultas) y volumen de datos? ¿Es siempre la misma relación? Indica las consultas donde consideres que un

incremento en el volumen de datos empeora de manera desproporcionada el rendimiento de la consulta. Intuitivamente, ¿Podrías explicar esta diferencia?

- Para las consultas 1, 5, 7, 14 ¿Qué puedes hacer para mejorar el rendimiento? Puedes cambiar la consulta (pero devolviendo los mismos datos) o puedes hacer cambios sobre la propia base de datos. Anota las diferencias antes y después de tu optimización. Explica tu mejora y a qué se debe la mejora en el rendimiento.
- Alcance de la entrega del ejercicio:
 - Tabla de tiempos de las consultas
 - Respuesta a las cuestiones planteadas.
 - Si hay algún cambio en la manera que has utilizado para rellenar la base de datos en el ejercicio anterior, apórtalo y documéntalo.