

Gestión de Riesgos Financieros

Bloque 3: Modelización de la volatilidad

Crisanto De los Santos Durán

May 6, 2026

Facultad de Ciencias Matemáticas

crisande@ucm.es

Agenda

¿Por qué modelizar la volatilidad?

Volatilidad histórica y ventanas temporales

EWMA: Media Móvil Ponderada Exponencialmente

Modelos GARCH

Volatilidad implícita

Comparativa de modelos

¿Por qué modelizar la volatilidad?

La volatilidad como input central

La volatilidad es el **ingrediente fundamental** de cualquier modelo de riesgo de mercado:

- El VaR paramétrico requiere estimar σ del activo o cartera
- La simulación de Monte Carlo necesita especificar la dinámica de σ
- Los modelos de opciones (BSM, GARCH) dependen directamente de σ
- La calibración de cópulas usa modelos de volatilidad para extraer los choques

Definición operativa

La **volatilidad** es la desviación estándar anualizada del cambio en el precio o valor de un activo financiero.

Problema central

La volatilidad **no es observable** directamente y **varía en el tiempo**.

Necesitamos modelos que la estimen y predigan.

Panorama de aproximaciones

Existen múltiples enfoques para estimar y predecir la volatilidad:

1. **Volatilidad histórica muestral** — ventanas fijas de datos pasados
2. **Estimadores de alta frecuencia** — usan datos intradiarios (Open, High, Low, Close)
3. **EWMA** — media móvil ponderada exponencialmente (RiskMetrics)
4. **Modelos ARCH/GARCH** — heterocedasticidad condicional autorregresiva
5. **Modelos de volatilidad estocástica (SV)** — σ_t sigue su propio proceso
6. **Volatilidad implícita** — extraída de precios de opciones observados

En este bloque cubriremos los enfoques 1, 3 y 4 en profundidad, y el enfoque 6 como conexión con el Bloque 6 de opciones.

Volatilidad histórica y ventanas temporales

Retornos logarítmicos

Trabajamos con **retornos logarítmicos** del activo:

$$R_t = \log \left(\frac{P_t}{P_{t-1}} \right), \quad t = 1, 2, \dots, T$$

Ventajas frente a retornos simples:

- Son **aditivos en el tiempo**: $R_{t,t+k} = \sum_{j=0}^{k-1} R_{t+j}$
- Más simétricos y mejor aproximados por la normal
- Estadísticamente más tratables

Suponemos $\{R_t\}$ covarianza-estacionaria:

$$\sigma^2 = \text{Var}(R_t) = \mathbb{E} [(R_t - \mathbb{E}[R_t])^2]$$

con estimación muestral:

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=1}^T (R_t - \bar{R})^2, \quad \bar{R} = \frac{1}{T} \sum_{t=1}^T R_t$$

Anualización de la volatilidad

La volatilidad estimada depende de la **frecuencia** de los datos. Para comparar entre frecuencias, se anualiza:

Frecuencia	Factor	Fórmula
Diaria	252 días hábiles	$\hat{\sigma}_{\text{anual}} = \sqrt{252} \hat{\sigma}_{\text{diaria}}$
Semanal	52 semanas	$\hat{\sigma}_{\text{anual}} = \sqrt{52} \hat{\sigma}_{\text{semanal}}$
Mensual	12 meses	$\hat{\sigma}_{\text{anual}} = \sqrt{12} \hat{\sigma}_{\text{mensual}}$

Este resultado se basa en la propiedad de que, bajo independencia de retornos:

$$\text{Var}(R_1 + R_2 + \cdots + R_n) = n \sigma^2 \implies \sigma_{n\text{-periodos}} = \sqrt{n} \sigma$$

Limitación

La raíz del tiempo asume retornos i.i.d., lo que **no** se cumple con GARCH.

El problema de la ventana temporal

La elección del tamaño de ventana T implica un **compromiso**:

Ventana larga (ej. $T = 250$)

- Mayor estabilidad estadística
- Menor varianza del estimador
- Reacciona **lentamente** a cambios en el régimen de volatilidad
- Puede mezclar periodos de alta y baja volatilidad

Ventana corta (ej. $T = 30$)

- Mayor reactividad a condiciones recientes
- Mayor varianza del estimador
- Puede **sobrereaccionar** a shocks puntuales
- Más útil en periodos de alta volatilidad

Observación clave

La volatilidad histórica con ventana fija pondera **igual** todas las observaciones dentro de la ventana — una observación de hace 249 días pesa lo mismo que la de ayer.

Estimadores de alta frecuencia: Garman-Klass

Cuando disponemos de datos OHLC (*Open, High, Low, Close*), podemos usar estimadores más eficientes que el estimador Close-to-Close.

Estimador de Parkinson (1976): usa el rango intradiario

$$\hat{\sigma}_{\text{Park}}^2 = \frac{(H_j - L_j)^2}{4 \log 2}, \quad \text{eff} \approx 5.2$$

Estimador de Garman-Klass (1980): combina todos los precios

$$\hat{\sigma}_{\text{GK}}^2 = 0.511(u_j - d_j)^2 - 0.019[c_j(u_j + d_j) - 2u_j d_j] - 0.383 c_j^2, \quad \text{eff} \approx 7.4$$

donde $u_j = H_j - O_j$, $d_j = L_j - O_j$, $c_j = C_j - O_j$.

Eficiencia

La eficiencia $\text{eff} \approx 7.4$ significa que Garman-Klass necesita **7 veces menos datos** que el estimador muestral estándar para alcanzar la misma precisión.

EWMA: Media Móvil Ponderada Exponencialmente

Motivación del EWMA

El estimador histórico pondera igual observaciones recientes y lejanas. El **EWMA** introduce ponderaciones decrecientes en el tiempo:

$$\hat{\sigma}_t^2 = (1 - \lambda) \sum_{j=0}^{\infty} \lambda^j R_{t-1-j}^2, \quad 0 < \lambda < 1$$

- λ es el **factor de decaimiento** (*decay factor*)
- Observaciones recientes reciben **mayor peso**
- La contribución de una observación de hace j periodos es $\propto \lambda^j$
- Para j grande, el peso $\lambda^j \rightarrow 0$ (memoria finita efectiva)

RiskMetrics (JP Morgan)

El estándar de la industria usa $\lambda = 0.94$ para datos diarios y $\lambda = 0.97$ para datos mensuales.

Recursión del EWMA

La fórmula del EWMA admite una **recursión extremadamente simple**:

$$\hat{\sigma}_t^2 = \lambda \hat{\sigma}_{t-1}^2 + (1 - \lambda) R_{t-1}^2$$

Interpretación:

- La varianza de hoy es un promedio ponderado de:
 - la varianza de ayer: $\hat{\sigma}_{t-1}^2$ (peso λ)
 - el retorno al cuadrado de ayer: R_{t-1}^2 (peso $1 - \lambda$)
- Solo necesitamos **dos valores** para actualizar la estimación
- Computacionalmente muy eficiente para implementaciones en tiempo real

Limitación del EWMA

El EWMA no tiene reversión a la media: si la volatilidad sube, el modelo predice que seguirá alta indefinidamente. GARCH corrige esto.

Elección de λ y vida media efectiva

El parámetro λ controla la **memoria** del modelo. La *vida media efectiva* es el número de días hasta que el peso se reduce a la mitad:

$$\tau_{1/2} = \frac{-\log 2}{\log \lambda}$$

λ	$\tau_{1/2}$ (días)	Uso típico
0.90	≈ 6.6	Volatilidad muy reactiva
0.94	≈ 11.2	RiskMetrics diario
0.97	≈ 22.7	RiskMetrics mensual
0.99	≈ 69.0	Memoria larga

λ puede estimarse por **máxima verosimilitud** o minimizando el error de predicción fuera de muestra.

Modelos GARCH

Del ARCH al GARCH

Engle (1982) introduce los modelos **ARCH** (*Autoregressive Conditional Heteroskedasticity*):

$$R_t = \sigma_t \varepsilon_t, \quad \varepsilon_t \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i R_{t-i}^2$$

Bollerslev (1986) generaliza con el modelo **GARCH(p,q)**:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i R_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Intuición

La volatilidad de hoy depende de los **retornos pasados al cuadrado** (efecto ARCH) y de la **volatilidad pasada** (efecto GARCH).

El modelo GARCH(1,1)

El caso más usado en la práctica es el **GARCH(1,1)**:

$$\sigma_t^2 = \omega + \alpha R_{t-1}^2 + \beta \sigma_{t-1}^2$$

Condiciones de estacionariedad y positividad:

- $\omega > 0, \alpha \geq 0, \beta \geq 0$
- **Persistencia:** $\alpha + \beta < 1$ (necesario para estacionariedad)
- Cuanto más cercano a 1 sea $\alpha + \beta$, más persistente es la volatilidad

Varianza incondicional (largo plazo):

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}$$

Reversión a la media

A diferencia del EWMA, GARCH predice que la volatilidad **revierte** hacia su nivel de largo plazo $\bar{\sigma}^2$.

GARCH(1,1) como generalización del EWMA

El EWMA es un caso límite del GARCH(1,1):

	EWMA	GARCH(1,1)
ω	0	> 0
α	$1 - \lambda$	Estimado
β	λ	Estimado
$\alpha + \beta$	$= 1$	< 1
Varianza LP	No definida	$\omega / (1 - \alpha - \beta)$
Reversión	No	Sí

El EWMA es un GARCH(1,1) con $\omega = 0$ y $\alpha + \beta = 1$ (*integrated GARCH* o IGARCH): la varianza incondicional no existe.

Propiedades empíricas de los retornos y GARCH

Los modelos GARCH capturan varios **hechos estilizados** de los retornos financieros:

- **Agrupamiento de volatilidad** (*volatility clustering*): periodos de alta volatilidad tienden a agruparse
- **Colas gruesas** (*fat tails*): los retornos tienen curtosis > 3 incluso si $\varepsilon_t \sim \mathcal{N}(0, 1)$
- **Efecto leverage**: caídas en el precio tienden a aumentar más la volatilidad que subidas equivalentes. Capturado por el **GJR-GARCH** (Glosten, Jagannathan, Runkle, 1993):

$$\sigma_t^2 = \omega + \alpha R_{t-1}^2 + \gamma R_{t-1}^2 1_{R_{t-1} < 0} + \beta \sigma_{t-1}^2$$

- **Autocorrelación en R_t^2** : los retornos al cuadrado están correlacionados

Estimación: por **Máxima Verosimilitud** (MLE). Bajo normalidad condicional, la log-verosimilitud es:

$$\ell(\theta) = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \left(\log \sigma_t^2 + \frac{R_t^2}{\sigma_t^2} \right)$$

Se maximiza numéricamente respecto a $\theta = (\omega, \alpha, \beta)$.

Predicción multi-paso: a partir de σ_t^2 conocido,

$$\mathbb{E}_t[\sigma_{t+k}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{k-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$$

La volatilidad predicha **revierte geométricamente** hacia $\bar{\sigma}^2$ a una tasa $(\alpha + \beta)$ por periodo.

Volatilidad implícita

¿Qué es la volatilidad implícita?

En el modelo Black-Scholes-Merton (BSM), el precio de una opción call europea es:

$$c_{\text{BSM}}(S, K, T, r, \sigma)$$

donde σ es el único parámetro no observable directamente.

La **volatilidad implícita** $\hat{\sigma}_{\text{imp}}$ se define como el valor de σ que iguala el precio teórico BSM al precio de mercado observado c_{mkt} :

$$\hat{\sigma}_{\text{imp}} = c_{\text{BSM}}^{-1}(c_{\text{mkt}})$$

- No tiene forma cerrada: se calcula numéricamente (Newton-Raphson, bisección)
- Puede calcularse contrato por contrato para diferentes strikes K y vencimientos T
- Refleja las **expectativas del mercado** sobre la volatilidad futura

Volatility Smile y Skew

Si el modelo BSM fuera correcto, la volatilidad implícita debería ser **constante** para todos los strikes y vencimientos.

En la realidad, se observan **patrones sistemáticos**:

- **Volatility smile**: la vol. implícita es mayor para opciones muy dentro o muy fuera del dinero que para opciones at-the-money
- **Volatility skew (smirk)**: las puts OTM tienen mayor vol. implícita que las calls OTM (asimetría hacia la izquierda de la distribución)
- **Term structure**: la vol. implícita varía con el vencimiento

Interpretación

La existencia de smile/skew es evidencia de que los retornos **no son normales**: el mercado asigna mayor probabilidad a caídas extremas que la distribución normal. Esto es consistente con los modelos GARCH.

Volatilidad implícita vs. volatilidad histórica

	Histórica	Implícita
Fuente	Precios pasados	Precios de opciones
Orientación	Retrospectiva	Prospectiva
Horizonte	Pasado	Hasta vencimiento
Incluye prima de riesgo	No	Sí
Modelo necesario	No	Sí (BSM u otro)
Disponibilidad	Siempre	Solo con opciones

Conexión con el Bloque 6

La volatilidad implícita será un concepto central en el estudio del riesgo en productos no lineales. El modelo BSM y sus extensiones (GARCH con valoración de opciones) se desarrollarán allí en profundidad.

Comparativa de modelos

Comparativa de modelos de volatilidad

	Hist. fija	EWMA	GARCH(1,1)
Ponderación	Uniforme	Exponencial	Exponencial
Reversión a la media	No	No	Sí
Parámetros	T (ventana)	λ	ω, α, β
Estimación	No	RiskMetrics	MLE
Predicción	Constante	Constante	Revierte a $\bar{\sigma}^2$
Coste computacional	Bajo	Bajo	Medio
Uso regulatorio	Básico	RiskMetrics	Estándar actual

Recomendación práctica

Para gestión del riesgo de mercado, el **GARCH(1,1)** es el punto de partida estándar. EWMA es útil para implementaciones simples y en tiempo real.