

Práctica 5. RRNN y Cálculo Paralelo

Siria Catherine Iñiguez Brito

20 de abril de 2026

1. Ejercicio 1: AND con Redes Neuronales

En esta sección se valida el uso del *Deep Learning Toolbox* de MATLAB para resolver un problema clásico de clasificación binaria: la función lógica AND.

Se diseñó una red con una arquitectura compuesta por una capa de entrada de dos dimensiones, una capa oculta con 2 neuronas y una capa de salida. Se compararon dos entornos de ejecución:

- **Versión Secuencial (`and_nn.m`):** Entrenamiento estándar mediante `train(net, X, Y)`.
- **Versión Paralela (`and_nnpar.m`):** Uso de *Distributed Computing Toolbox* mediante el parámetro `'useParallel'`, `'yes'`, distribuyendo el cálculo en los *workers* del `parpool`.

Tras completar el entrenamiento, se evaluaron las predicciones de ambos modelos. Los resultados numéricos obtenidos (Y_{pred}) frente al objetivo ideal $\mathbf{Y} = [0, 0, 0, 1]$ se detallan a continuación:

Configuración	Vector de Predicción (Y_{pred})			
Ideal (Objetivo)	0	0	0	1
Secuencial	0.5087	0.2950	0.4994	-0.0889
Paralela	0.0805	0.0501	-0.0337	0.0332

Cuadro 1: Comparativa de salidas de la red neuronal tras el entrenamiento.

1. **Variabilidad por Inicialización Estocástica:** La disparidad entre los resultados secuenciales y paralelos se debe a la naturaleza aleatoria de los pesos iniciales, pues cada entrenamiento comienza en un punto distinto.
2. **Subajuste (Underfitting):** Las predicciones muestran que la red no ha convergido al comportamiento de la puerta AND.

2. Ejercicio 2: Regresión - Distancia al Origen

El objetivo es aproximar la función de distancia euclídea $d = \sqrt{x^2 + y^2}$ mediante una red *feedforward*. Se generó un conjunto de 30,000 puntos para el entrenamiento y un conjunto independiente de 1,000 puntos para la validación final.

Método	Tiempo (s)	Speedup	Error Máx. Relativo
Secuencial (<code>error1</code>)	36.1128	—	0.0616
Paralelo (<code>error2</code>)	11.0764	3.26x	2.1876

Cuadro 2: Comparativa de Tiempos y Speedup (Red Feedforward)

Se comparó el tiempo de entrenamiento secuencial frente al paralelo. Los resultados obtenidos como se presentan en Cuadro 2 muestran una clara ventaja en el uso de múltiples núcleos para este volumen de datos.

Un aspecto crítico del análisis es la diferencia entre los errores obtenidos:

- **Error de Entrenamiento (`error1` y `error2`):** Representan el ajuste de las redes a los datos conocidos. La diferencia entre el error secuencial (0,0616) y el paralelo (2,1876) se debe a la naturaleza estocástica de la inicialización de pesos en MATLAB; cada proceso de entrenamiento parte de condiciones aleatorias distintas.
- **Error de Generalización (`error3`):** Al evaluar la red entrenada en paralelo con datos nuevos (X_3, Y_3), se obtuvo un error de **0.2811**.

3. Ejercicio 3: Reconocimiento de Dígitos

En esta fase se implementó un modelo de Deep Learning para la clasificación de dígitos manuscritos utilizando el dataset MNIST.

Se diseñó un Perceptrón Multicapa (MLP) compuesto por una capa de entrada de imagen, una capa completamente conectada (*fullyConnectedLayer*) de 100 neuronas con activación ReLU, y una capa de salida de 10 neuronas con *softmax* para la clasificación multiclase.

Se compararon dos configuraciones de entrenamiento mediante los scripts `num_d1.m` y `num_d12.m`:

- `num_d1.m`: Selecciona automáticamente la single CPU.
- `num_d12.m`: Fuerza el uso de la GPU mediante la opción '`ExecutionEnvironment`', '`gpu`'.

4. Ejercicio Final: Clasificación de Colores con CNN

El objetivo final consistió en desarrollar una Red Neuronal Convolutiva (CNN) capaz de identificar seis categorías de colores: rojo, verde, azul, amarillo, negro y blanco.

Se generaron 100 imágenes ($32 \times 32 \times 3$) por categoría introduciendo:

- **Perturbación tonal:** Variaciones de ± 30 en los valores RGB base.
- **Ruido de píxel:** Variación aleatoria de ± 80 en cada píxel para simular ruido digital.

Se evaluó el tiempo de entrenamiento de la CNN diseñada bajo diferentes entornos:

Entorno de Ejecución	Tiempo (s)	Precisión (%)
'cpu' (Multinúcleo)	6.75	100.00 %
'gpu' (Single GPU)	7.35	100.00 %

Cuadro 3: Resultados del Ejercicio Final (Deep Learning)